用 Agent 构造大规模知识库

以《史记》知识库为例

鲍捷 · baojie.github.io/shiji-kb · github.com/baojie/shiji-kb · 2026-03-19

PART I：成果

PART II：管线 SKILL

PART III：元技能 Metaskill

PART I

我们用 AI 在《史记》上做到了什么

57万字 · 10万实体 · 3185事件 · 7652关系

核心成果：全量结构化

130篇

57.7万字

18类实体语义标注
100% 全覆盖

12,380

词条

实体标注 99,214 次
人名 / 地名 / 官职等18类

3,185

个事件

11类事件类型
98.7% 标注公元纪年

7,652

条关系

9种关系类型
1876条跨章关系

675

知识单元

434 事实 + 241 技能
可直接喂给大模型

26

个 SKILL

9大阶段全覆盖
换一部书，管线不变

知识库能做什么

语法高亮阅读器

18类实体着色
平均每6字1个实体
对话浮现·三家注弹窗

事件地铁图

130条线·3185个站
跨章换乘·时间轴
前2700年→前87年

知识图谱查询

人物关系·势力版图
事件因果链
直接喂给大模型

可复用知识单元

434项事实
241项历史技能
内容创作·游戏化

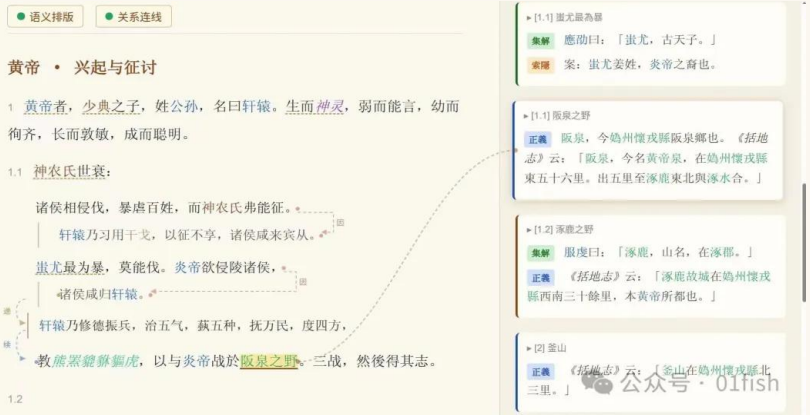

扩展路线：《史记》→ 二十四史 (4600万字) → 四库全书 (数亿字)

PART II

构造管线 SKILL

换一部书，管线不变，参数调整，即可构造新知识库

九大阶段 · 从原始文本到知识应用

01 校勘 1个SKILL

多版本比对·底本校正

02 结构分析 9个SKILL

章节切分·段落编号·三家注

03 实体构建 5个SKILL

18类NER·消歧·多轮反思

04 事件构建 6个SKILL

事件提取·纪年推断·年代审查

05 关系构建 5个SKILL

9种关系·人物/地点·SPO三元组

06 本体构建 2个SKILL

词表→分类树→OWL/RDF

07 逻辑推理 4个SKILL

矛盾检测·生卒年推断·姓氏推理

08 SKU构造 1个SKILL

事实/技能/关系知识单元

09 应用构造 3个SKILL

阅读器·地铁图·游戏化

四层语义递进模型

4 应用语义

考据推理 · 矛盾发现 · 规律归纳 · 历史叙事重构

09 应用构造

3 知识语义

分类体系 · 推理规则 · 知识单元（SKU）

06 本体 07 推理 08 SKU

2 图谱语义

人物/地点/事件识别 · 消歧 · 关系发现 · 原子事实

03 实体 04 事件 05 关系

1 结构语义

切分 · 编号 · 因果/并列/递进 · 注释对齐

01 校勘 02 结构分析

SKILL 设计原则：每个工序都是可执行的文档

输入/输出规范

每个SKILL明确定义：接收什么格式的文本，产出什么格式的数据

标注规则

18类实体的边界定义、消歧规则、异体字处理，覆盖所有边缘情况

质检工具 (Lint)

五层质检体系：格式→统计→一致性→语义→跨章，每层都有自动脚本

常见错误索引

从实际错误总结的 Checklist，避免重复犯同一类错误

多轮反思流程

按章反思 → 按类型反思 → 跨章一致性检查，错误率 20%→3%

LLM + 规则混合

LLM 做语义理解，规则脚本做格式验证，成本最优分工

迁移参数

换书只需调整：实体类型 / 体裁分类 / 别名规则 / 年份体系

直接可执行

将 SKILL 文档 + 待处理文本一起交给 Claude Code，即可运行

PART III

元技能 Meta-skill

与具体数据类型无关的通用方法论 · 适用于任何大规模知识工程项目

元元技能：好东西都是总结出来的

OTF

On The Fly

即时总结

发现模式的那一刻立即记录

3次重复 → 立即归纳规则

JIT

Just In Time

及时交付

MVP优先，快速迭代

60% → 80% → 92% → 97%

Bootstrap

自举增殖

知识增殖

每一步迭代产生下一步的元知识

人工干预递减，自动化指数增长

OTF × JIT × Bootstrap = 自举式知识增殖系统

14 个元技能 · 两层架构

方法论层	M00	M01	M02	M03	M04	M05	M06
	好东西都是总结出来的	反思	迭代工作流	冷启动	柳叶刀方法	知识作为上下文压缩	SKILL优化与演化
	元元技能	Agent质量审查	MVP→收敛	5样本→MVP	精细分解	KG价值论	方法论迭代
执行层	M07	M08	M09	M10	M11	M12	M13
	可读性	标注体系设计	Agent提示词工程	质量控制	数据体感培养	数据融合	技能迁移
	人类优先格式	语义标记工程	五层金字塔	五层Lint体系	十层观察体系	多源对齐消歧	跨项目复用

几个核心元技能详解

M01 反思

- 按章反思→按类型反思→跨章一致性
- Agent 自主发现系统性错误模式
- 错误率：20%→5%→3% 多轮收敛

M04 柳叶刀方法

- LLM 做语义 / 规则脚本做验证 / 代码做批量
- 古文多义词极多，不能用关键词匹配
- 混合方案矩阵：精度×速度×成本三角

M09 提示词工程

- SKILL 文档 = Agent 的 DNA
- 五层金字塔：原则→规则→示例→反例→边界
- SKILL 是积累出来的，不是一次写完的

M10 质量控制

- 五层质检：格式→统计→一致性→语义→跨章
- 每层都有自动 Lint 脚本，形成闭环
- Lint 规则来自实际错误案例总结

人机协作分工：一人 + 一群 Agent

人（决策者）

· 定义愿景，设计标注体系

· 审美判断，纠正语义错误

· 质量把控，最终决策

· 元技能总结与 SKILL 迭代

· 跨项目迁移策略制定

⇄

AI（执行者）

· 大规模 NER 实体标注

· 代码开发 · 批量文件操作

· 渲染管线 · 文档生成

· Lint 工具链运行

· 知识图谱结构化输出

如何用同一套管线处理另一部书

1

获取 SKILL 文档

git clone https://github.com/baojie/shiji-kb
cd skills/ — 26个SKILL文档，即取即用

2

调整4个参数

实体类型 · 体裁分类 · 别名规则 · 年份体系
框架不变，参数变，无需重新设计管线

3

交给 Claude Code 运行

将 SKILL 文档 + 待处理文本交给 Agent
Agent 按管线自动执行，人只做质检和纠错

4

迭代与收敛

P0→P1→P2→收敛，每轮OTF总结错误模式
更新SKILL文档，下一轮自动化率提升

迁移案例：金融语料（公告 & 年报）

只需调整的 4 个参数

实体类型
原：人名 / 地名 / 官职 / 朝代
新：公司 / 高管 / 财务指标 / 监管机构 / 证券代码 / 风险因素

体裁分类
原：纪传体 / 表 / 书 / 本纪
新：定期报告 / 临时公告 / 问询函回复 / 招股书

别名规则
原：谥号 / 字 / 封号 / 短称
新：股票简称 / 曾用名 / 子公司 / 简称映射

时间体系
原：在位纪年 → 公元年推断
新：会计年度 / 报告期 / 披露日期三轨对齐

管线跑完后能得到什么

① **公司实体图谱**
母/子/参股公司关系网络
高管任期 · 交叉持股 · 关联方穿透

② **财务事件时间线**
融资/并购/诉讼/分红/违规
跨公告自动串联，消除重复披露噪音

③ **风险信号知识单元**
审计意见变化/商誉减值/限售解禁
结构化为可检索 SKU，直接喂模型

④ **监管语义合规检查**
信披格式 lint · 前后矛盾检测
同一指标跨期异常自动标记

实战：把金融数据获取部署在 Claude Code (龙虾) 里

01 一键安装 Skill

- **npx skills add lihanghang/clawshire-open-skill**
- 或：claude skill install <github-url>
- 设置 CLAWSHIRE_API_KEY 环境变量

02 自然语言查询

- **帮我查最近有股票异常波动的公司**
- 003041 近期公告分析
- 纳百川最近3个月有哪些催化因素

03 Skill 自动完成

- **调 /api/v1/announcements 取结构化 JSON**
- 自动整理成投研报告 / 表格 / 时间线
- 可接钉钉/飞书 Webhook 实时推送

支持 14 类结构化提取（infotype 参数直接传中文名）

人事变动	97.7%
董事会决议	—
业绩预告	98.7%
股票交易异常波动	100%
核心技术人员离职	100%
重大资产重组	95%
变更会计师事务所	100%

数据来源：clawshire.cn · API：api.clawshire.cn · 每 Key 免费 100 次 · 公告发布后 1～3 分钟内完成提取推送

实战案例：龙虾对爬取数据的异常波动逻辑分析

真爱美家（003041）近期公告 · Agent 结构化提取 + 因果推理

● 真爱美家（003041）近期公告详情

3月以来共 6 条公告，背后有一条清晰的主线：控制权变更。

事件时间线

日期	公告	核心内容
03-03	为全资子公司提供担保的进展公告	2025年度对外担保额度不超过13亿元，连带责任保证
03-11	控股股东协议转让股份完成过户，控制权发生变更	真爱集团将 29.99% 股份（4318.56万股）协议转让给广州探迹远擎科技合伙企业，转让价格27.74元/股，过户日 2026-03-09，实际控制人变更为黎展
03-12	探迹远擎要约收购提示性公告期满120日的说明	2025-11-12披露要约收购报告摘要，拟通过部分要约方式进一步增持
03-13	股票交易风险第二次提示性公告	股价连续上涨后的风险警示，明确：①无重大资产重组计划 ②主营业务仍为毛巾家纺，不涉及AI ③市盈率120.64，远高于行业均值29.08 ④媒体"借壳上市/变更主营"传言不实
03-14	为全资子公司提供担保的进展公告	同03-03，定期进展披露
03-16	股票交易异常波动公告	3/12、3/13 连续2日涨幅偏离值累计超过20%，触发异常波动披露义务

核心结论

股价异动的直接驱动因素是控制权变更：

- 新实控人广州探迹远擎（科技背景）入主一家传统家纺企业，市场产生"借壳+转型AI"的炒作联想
- 公司在风险提示中明确辟谣：主营业务未变，不涉及AI，无重大资产重组计划
- 估值严重偏离：静态市盈率 **120.64**，行业均值仅 **29.08**，溢价超 4 倍
- 属于典型的控制权变更炒作行情，基本面无支撑，风险极高

完整 SKILL 索引 · 所有方法论文档链接

元技能 MetaSkill	构造管线 SKILL（01–05）	构造管线 SKILL（03c–09）	构造管线 SKILL（07–09）+ ClawShire
META-00 好东西都是总结出来的	SKILL-00 管线总览	SKILL-03c 实体标注反思	SKILL-07 逻辑推理
META-01 反思	SKILL-01 古籍校勘	SKILL-03d 渲染与发布	SKILL-07a 人物生卒年推断
META-02 迭代工作流	SKILL-02 结构分析	SKILL-04 事件构建	SKILL-07b 姓氏推理
META-03 冷启动	SKILL-02a 章节切分与编号	SKILL-04a 事件识别	SKILL-07c 反常推理
META-04 柳叶刀方法	SKILL-02b 区块与韵文处理	SKILL-04b 十表事件处理	SKILL-08 SKU构造
META-05 知识作为上下文压缩	SKILL-02c 三家注标注	SKILL-04c 事件年代推断	SKILL-09 应用构造
META-06 SKILL优化与演化	SKILL-02d 结构语义分析	SKILL-04d 事件年代审查	SKILL-09a 认知辅助阅读器
META-07 可读性	SKILL-02e 词法分析	SKILL-04e 年份消歧	SKILL-09b 知识库游戏化
META-08 标注体系设计	SKILL-02f 文本统计	SKILL-05 关系构建	**ClawShire API（金融公告）**
META-09 Agent提示词工程	SKILL-02g 表格结构语义分析	SKILL-05a 事件关系发现	API 完整文档
META-10 质量控制	SKILL-02h 词表构建	SKILL-05b 实体关系构建	快速上手教程
META-11 数据体感培养	SKILL-03 实体构建	SKILL-05c 人物关系构建	钉钉/飞书推送配置
META-12 数据融合	SKILL-03a 实体标注	SKILL-05d 事实发现	为什么需要结构化提取
META-13 技能迁移	SKILL-03b 实体消歧	SKILL-06 本体构建 / 06a 实体到本体	Clawshire Open Skill (npx)

史记知识库 SKILL：https://github.com/baojie/shiji-kb/tree/main/skills **ClawShire API**：https://api.clawshire.cn/scalar **ClawShire Skill**：https://github.com/lihanghang/clawshire-open-skill

愿景

建立一个由 AI Agent 维护和持续进化的知识网络，
让任何人都能以问答、可视化、推理的方式
探索数千年的智慧。

在线体验： baojie.github.io/shiji-kb

开源仓库： github.com/baojie/shiji-kb

作者： 鲍捷 / baojiexigua

《史记》只是一个起点 · 当前只完成了 1%