



Butler 自进化过程报告

日期：2026-04-23

范围：从种子指令到 R50（史记 wiki Butler Agent 完整演进记录）

版本：v2（新增"信息组织框架"与"日志中发现的知识"两节）

一、背景与定义

Butler 是史记知识库项目中用于组织 wiki 知识页面的 Agent。它的使命是把已有的分散知识资产（kg / doc / data / ontology-v2 / logs）组织到 `wiki/public/pages/` ——不是内容生产者，是厨师，原材料在别处，butler 负责摆盘与拼盘。

"自进化"是指 Butler 具备一套机制：每执行 20 个原子动作后，自动扫描执行日志、识别系统性问题、提出修订提案，并更新自身的 Skill 文件。这套机制让 Butler 在运行中持续改善自己的工作方式，而不需要人工重写提示词。

本报告记录从种子指令（2026-04-22）到 R50（2026-04-23）的完整演进过程，重点关注：每个阶段 Butler 学到了什么、纠正了什么、以及这些修正如何积累成更高质量的输出。

二、种子指令（2026-04-22，提交 91416380）

2.1 诞生时刻

Butler 在一次提交中同时创建了六个 Skill 文件，这是整个自进化系统的起点：

Skill	职责
W0 总则	六不变量 + "观察→行动→留痕→评估→反思→进化"闭环
W1 探索与食物收集	6 个食物源 + 候选队列 + 2:1 顺藤/探索配比
W2 原子行动目录	18 种原子操作，每次仅取一种

Skill	职责
W3 质量标准	5 维度打分 rubric (信息量/结构/引证/内链/时间线)
W4 评估与检验	before/after 评分 + 6 个红旗否决条件
W5 反思与自改	周期反思引擎，可修改 W1-W4 (不可修改 W0、W5 自身)

2.2 六不变量 (绝对约束)

1. 小步：每次 commit 的 diff ≤ 20 行
2. 可逆：每个动作 $\leftrightarrow$ 1 个 commit，失败时 `git revert` 即可回滚
3. 留痕：每个动作写 `logs/wiki_butler/actions.jsonl`，含动机/前置/后置/来源
4. 自改：Skill 文件可被 W5 修改，但必须走"反思→提案→changelog"流程
5. 禁编造：不写原文未支持的"事实"，所有断言需溯源
6. 消化不生产 (后被移除)：只搬运/组织既有资产，不新创作长文

2.3 种子指令的核心哲学

宁可 100 次小改动 (20 次失败 + 80 次留下)，不做 1 次大改动 (成败未知)。Butler 的"智能"不在每次多好，而在于随时间单调改进。

值得注意的是：种子指令诞生的那一刻，W5 反思机制就已经运转——同一次提交里包含了第一轮 W5 反思的执行结果 (stub 模板 59 行 → 20 行)。框架的第一件事就是纠正自己。

三、早期反思循环 (v1–v8，2026-04-22 至 2026-04-23)

3.1 第一轮反思 (W5 v1)：发现系统性冲突

触发：累计 20 条原子动作后。

数据快照：20 条记录，19 accept / 1 fail；75% 是 create-stub；平均 diff 47.4 行。

识别的 6 个模式：

模式	问题	处理
A	create-stub 平均 47.4 行，违反 W0 的 ≤ 20 行不变量	压缩 stub 模板：59 行→20 行
B	79% 行动是 create-stub，长期只有 stub 无深度	动态配比（队列大时 3:1，小时 1:1）
C	KG 层噪音（汉孝文帝/秦张仪等错误 canonical）导致失败	加 canonical 质量前置过滤
D	trail 17/explore 1，远未达 2:1 配比	动态调整：队列 >10 时 3:1，<5 时 1:1
E	create-stub 一律 0→5，打分无区分度	留待后续迭代
F	6 次新建页只做了 1 次 rebuild-registry	留待后续迭代

关键提案（3 条）：

1. create-stub 模板压缩（与 W0 对齐）
2. discover_kg.py 加 canonical 质量过滤
3. W1 探索配比从静态 2:1 → 按队列大小动态调整

3.2 第二轮反思（W5 v2）：验证 + 发现新问题

触发：前次反思后累计 22 条动作。

对上轮提案的验证：

- ✓ 提案 1（stub ≤ 20 行）：平均 diff 从 47.4 → **14.6** 行，降幅 69%，不变量不再冲突
- ✓ 提案 2（canonical 过滤）：跳过 6 个 bad canonical
- 🟡 提案 3（动态配比）：部分有效，但 SKU 源已耗尽导致探索无对象

新识别的模式：

- 模式 G：两个 canonical 共享强别名（如"胡亥"），用规则扫不到，需 alias 交集检测
- 模式 H：手动拍 tag 主观性破坏一致性，需要词表 + 自动推断
- 模式 I：enrich-infobox 0 次调用（等待 KG 增量，不修）
- 模式 J：SKU 源已耗尽（自然降权，不修）

提案（3 条）：

1. `findLikelyDuplicates()`：用 `alias` 交集检测 `canonical` 重复对
2. `tags_vocabulary.json` + `discover_tags.py`：era / identity / theme 三组自动推标签
3. W1 源耗尽降权（连续 5 次空探索 `weight×0.5`）

3.3 第三、四轮反思（W5 v3/v4）：打分精细化

核心修订：

- `narrative_bonus`：页面有散文段落 ≥ 2 块 +8，有 `<!-- stub:` 标记 -5 ——让质量分能区分空骨架和有内容的页面
- `era_tag` 改用 `death_ce`（原用 `birth_ce` 导致刘邦被误推为"战国"）
- `recent.json` 上限 500 + 归档机制
- `discover_doc.py` 新增：从文档层发现引证候选

来自用户的紧急反馈（绕过 W5 流程直接应用）：

- #1： `recent.json` 分页（不再 50 条截断）
- #2： `quality_score` 多因子计算
- #3：独立 /all 页按 `type` 分组

这促使 W5 协议区分 `user-req` 和 `w5-reflect` 两种来源，并在 `skill_changes.md` 中分别标记。

3.4 第五轮反思（W5 v5）：扩写启动

背景：用户反馈"基本都是空骨架"——系统建了大量 `stub` 但没有实质内容。

处理：

- `SKILL_W1 §3.4`：当站点 `median quality < 10` 时，优先深度（`enrich > create-stub`）
- `clean-stub` 条件扩展：`tags $\geq$ 3 OR cite OR timeline` 时清除 `stub` 标记
- `enrich_timeline.py`：清理标注语法（`[[TYPE value]]` → 保留 `value`），146 页时间线全量重写

3.5 第六轮反思（W5 v6）：自诊断工具化

关键创新：新增 `reflection_scan.py`。

此前 W5 反思依赖 Butler 自己"回顾"日志，这是软性的。v6 引入了硬性自诊断：自动扫描 `alias_conflicts` / `duplicate_candidates` / `no-timeline` / `quality-bottom` 四类问题，生成结构化报告供 W5 引用。

这是一个重要的元进化：**Butler** 给自己的反思过程增加了工具支撑，让反思更客观、更系统。

3.6 v7 Bug Fix：精确度 vs. 召回率的取舍

触发：用户报告"鲁桓公"时间线被错误填充——"桓"字匹配了所有含"桓"的人名。

修复：`enrich_timeline.py` 改用 `【@】` 严格正则，单字别名禁用于匹配，195 页时间线全量重写。

这次修复揭示了一个普遍规律：正则匹配在古汉语人名中极易过匹配，因为谥号（桓/文/武/昭）大量共用。从此所有别名匹配均要求长度 > 1。

3.7 v8 知识量度量（2026-04-23 01:05）：引入可量化目标

背景：此前 Butler 的评估维度是 per-page 的 `quality_score`，没有全站总量度量，无法知道整体进展。

引入 **K** 公式：

```
K = Σ_page log2(1 + bytes) × (1 + min(links_density, 5)) × type_weight × quality_norm

type_weight = {person/event/place/state: 1.0, topic: 0.8, surface: 0.5}
quality_norm = clamp(quality_score / 30, 1.0, 3.0)
```

首次快照：

指标	数值
K	13,336.34
页面数	229
精品页	10
链接命中率	20.8% （核心诊断）

指标	数值
最大贡献页	项羽(189 wikilinks) / 刘邦(186) / 孔子(166)

诊断暴露最大缺口：前 25 个死链目标全部是章节页（NNN_章名）——因为 wiki 根本没有章节类型页面。批量生成 130 个章节 stub，链接命中率可一步从 20% → 40%+。

K 度量的引入是一个范式转变：Butler 从此有了可量化的优化目标，而不只是"继续生产"。

四、不变量级别的修订：移除"消化不生产"

这是整个自进化过程中唯一一次不变量级别的修订，发生于 2026-04-22 下午（提交 24a8c087）。

原不变量 #6："只搬运/组织既有资产，不新创作长文。"

修订过程：

- 1. 用户要求 Butler 建精品页，做叙事综合
- 2. Butler 先建了 3 个精品页样本（刘邦/项羽/孔子），证明可行性和价值
- 3. 确认样本质量后，用户要求正式移除第六不变量
- 4. 约束转移到已有的"禁编造"：所有"生产"仍需有源断言

意义：这次修订改变了 Butler 的根本角色定位——从"搬运工"扩展为"厨师"，可以在有材料来源的前提下进行叙事综合和分析写作。此后精品页扩写成为 Butler 的核心产出形式。

五、规模扩张期（R 序列前的精品页批量扩写）

v8 之后、规范化 R 编号之前，Butler 经历了一段高强度的精品页批量扩写：

批次	规模	K 值	备注
Butler 插件系统 + 精品人物页	×19	—	插件架构 + Special 路由

批次	规模	K 值	备注
精品人物页扩写	×23	—	Special 知识量动态页
精品人物页扩写	×8	—	张苍/梁孝王/淳于意等
精品人物页扩写	×12	—	修复 featured 计数
精品页扩写 + 深化	×3 + ×1	16,741	赵简子/周厉王/陈豨/伊尹
精品页扩写 + 深化	×30 + ×8	17,494	荀瑶/赵惠文王/颜回等
W6 质检修复 + 精品扩写	×30+	—	韩王信编造引文事件

韩王信事件是这一阶段的关键转折点：W6 离线质检发现 Butler 在韩王信条目中写入了原文不支持的引文。这暴露了批量扩写模式下"禁编造"不变量的执行压力，直接推动 W6 质检流程独立化和规范化，并在后续所有 R 轮次中变为标准步骤。

六、规范化轮次（R35–R50）

从 R35 起，每轮输出格式固定为：

3 个精品页 + 1 个深化 + W6 质检 + K 快照，一次提交一轮。

6.1 K 值时间线

轮次	K 值	代表人物
R35	17,807	孙武 / 淮南厉王 / 蒯通 / 郑厉公
R36	17,820	燕昭王 / 帝喾 / 晋厉公 / 齐惠公
R37	17,816	周康王 / 任安 / 鲁桓公 / 叔带
R38	17,847	晋顷公 / 秦孝文王 / 戚夫人 / 晋定公
R39	17,842	帝颛顼 / 秦襄公 / 晋灵公 / 楚惠王
R40	17,803	鲁隐公 / 宋微子 / 晏婴 / 蒙骜

轮次	K 值	代表人物
R41	17,769	扁鹊 / 崔杼 / 晋悼公 / 箕子
R42	17,718	黄歇 / 陆贾 / 叔孙通 / 季札
R43	17,697	宋襄公 / 吴王阖闾 / 张释之 / 齐庄公
R44	17,792	田横 / 栾布 / 蔡泽 / 周昌
R45	17,794	刘敬 / 郅都 / 王温舒 / 鲁仲连
R46	17,754	刘濞 / 石奋 / 王陵 / 灌婴
R47	18,318	齐悼惠王 / 刘武 / 中山靖王 / 楚平王
R48	18,309	汉武帝 / 刘如意 / 齐宣王 / 陈馥
R49	18,280	秦惠王 / 周宣王 / 晋惠公 / 曹参
R50	18,265	卫康叔 / 刘兴居 / 秦文公 / 卢绾

6.2 K 值震荡分析

R37–R43 出现了 K 值轻微下降（17,847 → 17,697）的震荡区间，而非单调增长。原因是这一阶段 W6 质检检出并修复了多个编造引文问题，修复操作（删除虚构内容）导致页面体积减少，从而拉低 K。

这是健康的：K 的下降反映了质量控制机制在正常工作，而不是 Butler 退步。R47 的 K 值跃升（17,754 → 18,318）则表明质检收敛后，新增内容的净增量重新主导。

七、Butler 自发现的信息组织框架

Butler 在构建精品页的过程中，从具体问题倒推出了若干信息组织方式。这些框架不是预先设计的，而是在解决实际困难时自然归纳出来的。

7.1 互见法的显性化

《史记》本身使用"互见法"——同一人物散落在多篇，读者需自己跨篇拼图。刘邦的形象分布在

高祖本纪、项羽本纪、萧相国世家、淮阴侯列传等处，读原书时这是隐性的。

Butler 在构建精品页时摸索出把互见法显性化的组织方式：

《史记》本传见高祖本纪，另于项羽本纪、萧相国世家等篇以互见法反复映照，形象之立体为《史记》人物刻画之巅峰。

"相关章节"一节按三层组织：本传→三杰世家列传→功臣列传→年表。这个分层是做了数十个精品页后归纳出来的，不是事先规定的。

7.2 时间线的溯源格式

最初时间线从 KG 直接导出，含大量标注符号（ [[@ 刘邦]] 于 [[◆沛]] 起兵 ）。清理噪音是显然的一步，但 Butler 同时发明了一种溯源格式：

- 前 209 秋 · [[陈胜]]反于[[蕲]]，刘邦**起兵沛县** [`008-008` , `008-009`]

反引号里的 008-008 是 KG 中的事件编号，可追溯到原文具体段落。这解决了百科叙述（可读性）与历史材料（可验证性）之间的矛盾——两者不必取舍，用 inline 引用并存。

7.3 人物关系的分层分类

最初"相关人物"是一个 flat list。做了刘邦、孔子、韩信等多个精品页后，Butler 发现 flat list 不可用，自己归纳出了分层：

家族 - [[刘太公]] · [[吕雉]] · [[刘盈]] ...
汉初三杰 - [[张良]] · [[萧何]] · [[韩信]]
沛县旧友 - [[曹参]] · [[樊哙]] · [[周勃]] ...
对手 - [[项羽]] · [[章邯]] ...
异姓王（后被诛）- [[韩信]] · [[彭越]] · [[英布]] ...

最后一类"异姓王（后被诛）"尤为典型——这是 Butler 从多个人物的关系弧线中归纳出的历史模式分类：从盟友到被诛，结构相似，值得单独成组。这个分类不存在于史记原文，是信息组织层的新增语义。

7.4 知识量 K 的信息论设计

v8 引入 K 时面临一个选择：用字节数线性求和最直觉。Butler 选了：

$$K = \sum \log_2(1 + \text{bytes}) \times (1 + \text{links_density}) \times \text{type_weight} \times \text{quality_norm}$$

log2 而非线性：防止一个 3000 行的巨页压过 30 个中等页——隐含了"知识价值边际递减"的信息论直觉。

links_density 加成：孤立的页面即使写得好，也不如被广泛链接的页面有价值，因为链接是知识嵌入网络的程度。

这个公式在初次快照时立刻诊断出了链接命中率 20.8% 的缺口——因为公式的设计使得链接稀疏的页面得分打折，量化工具倒逼出了下一步的优先级。

7.5 semantic-block 的信息分层

wiki/public/plugins/semantic-block/index.js 做了一件结构上重要的事：把 YAML frontmatter 里的元数据通过 data-meta 属性暴露给 JavaScript 层，让其他插件可以查询 core.semanticBlock.getPageMeta() 。

这对应了信息组织的三层分离：

数据层	YAML frontmatter	→ 结构化元数据，机器可读
呈现层	HTML 渲染	→ 人类可读的页面
交互层	JS 插件	→ 可查询的 API

驱动力是：Special:知识量动态页需要读取所有页面的 quality_score 来渲染排行，光靠静态 HTML 不够，需要一个从页面元数据提取信息的机制。功能需求倒推出了架构分层。

八、日志中浮现的具体知识

Butler 的失败日志 (failures.jsonl 、 citation_issues.jsonl) 不只记录了系统问题，还把史记文本本身的一些隐性结构暴露出来。

8.1 编造引文：6683 条，规模与分布

`citation_issues.jsonl` 记录了 W6 质检扫出的引证问题：全部 6683 条，全部类型 `FABRICATED_QUOTE`，全部状态 `open`（尚在修复中）。

按受影响页面数量排名：

页面	问题条数
陈平	174
刘邦	171
鸿门宴	156
萧何	150
赵高	150
韩信	142
伍子胥	138
司马迁	129
管仲	122

这个分布本身是一个发现：越是“知名度高”的人物和事件，编造引文越多。因为模型对这些人物的“了解”更多，更容易生成听起来合理的文言文，但合理不等于原文存在。

W6 的具体机制是 `grep_result: "not_found"` ——在去标注的干净原文中找不到对应文字。注意这里混有两种情况：真正的编造，以及原文确实存在但因字形变体/标注处理导致 `grep` 失效。两者从记录外观上难以区分，需要人工逐条核查。

8.2 韩王信：真伪引文的对比

韩王信案例可以看到编造引文和真实引文的直接对比。

修复前（W6 判为编造，删除）：

"汉与我，约为兄弟。今汉既往而不咎，吾亦得归，然恐归汉而复受辱，故不敢归。生为汉臣，死为汉鬼，岂有异哉！"

修复后（原文 093-009，保留）：

"今仆亡匿山谷间，旦暮乞贷蛮夷，仆之思归，如痿人不忘起，盲者不忘视也，势不可耳。"

两段话讲同一件事（韩王信拒绝归汉），语气也接近，但真实引文更具体、更个人："痿人不忘起，盲者不忘视"是一个非常独特的比喻，是真实人物说出的真话。生成版本则是"正确但平庸"的文言文，用套语代替了细节。

这个对比揭示了史记文本的一个核心价值：史记的价值恰恰在于这些具体的、不可替代的细节，而模型的补全会把它磨平成泛化的历史叙事。

8.3 鲁桓公：谥号是歧义密集的命名系统

v7 反思复盘里记录：鲁桓公（在位前 712–694，被齐襄公所杀）的时间线里，出现了：

- 前 562：三桓分军（鲁襄公时期，晚于鲁桓公死亡 132 年）
- 前 468：哀公欲伐三桓（鲁哀公时期，晚于鲁桓公死亡 226 年）

原因是鲁桓公别名包含"桓"（单字），而"三桓"（鲁桓公三个儿子后裔的合称）也含此字，子串匹配直接误中。

这暴露了中国古代谥号系统的一个系统性问题：桓/文/武/宣/昭/景/庄/哀等谥号，同时用作数十个君主的单字称呼，又出现在族称（三桓）、地名（桓公台）、复合称呼（齐桓公）里。史记时代读者靠上下文区分，但数据库化后，这个隐性上下文必须显式化为 `[[@ 鲁桓公]]` 这样的标注才能准确。

8.4 刘舜 = 虞舜：上古传说人物的边界

failures.jsonl 第一条：

```
"target": "wiki/public/pages/刘舜.md",  
"red_flags": ["canonical_error: 刘舜 实为虞舜, KG 消歧错"]
```

KG 里有个"刘舜"，引用次数 81，被系统归为汉代刘姓人物。Butler 准备建页时发现：这是上古五帝之一虞舜，与汉代刘氏毫无关系。

这反映了史记的一个特殊结构：司马迁试图把上古传说（五帝）和有文字记录的历史（商周以下）接续成一条线。使得史记里同时存在神话人物（虞舜、大禹）和历史人物，它们混在同一套

人名系统里，批量处理时极易被错误归类。

8.5 楚平王生年：即位年 ≠ 出生年

提交 `ab33e744` 修正：楚平王（公子弃疾）的 `birth_ce` 从 `-528` 改为约 `-560`。

`-528` 是他的即位年。KG 构建时把即位年误当成了出生年。楚平王以政变夺位，即位时已是成熟的政治行动者，生年应倒推至前 560 左右。

这个错误很典型：史记在叙述很多君主时，记的是登基年而不是出生年（出生年经常不知道）。批量建立 KG 时，“年份”字段如果不区分“生年/即位年/死年”，就会系统性地产生此类混淆。

8.6 共同的发现

这五类日志问题各自来自不同的失败类型，但指向同一个深层洞察：

史记文本的信息结构不是扁平的。它包含：

- 原文直引（可 `grep` 验证）
- 作者叙述（合理但不是引文）
- 上古传说（神话与历史混合）
- 隐性消歧（读者靠上下文区分“桓”指谁）
- 年份的多义性（即位年/生年/纪年混用）

Butler 的日志系统通过记录失败，把这些隐性的文本结构问题一条条浮出了水面。这本身是一种知识发现——不是关于历史事件的知识，而是关于这部文本是如何组织信息的知识。

九、知识积累与自我纠正的结构性规律

9.1 三层纠错循环

第一层（每 20 步）：W5 反思 → 识别日志模式 → 提案 ≤ 3 条 → 修改 W1–W4

第二层（失败即触发）：`failures.jsonl` → 专项 `bug fix` → 全量数据重写

第三层（用户反馈）：`user-req` → 紧急修订 → 可能触及不变量级别

关键约束：自进化从不修改 W0（总则）和 W5（反思引擎本身）。W0 的唯一一次修订是用户主动推动，且有样本验证。这保证了系统稳定性——进化引擎不自我改写自己。

9.2 提案保守原则的作用

W5 每轮最多 3 条提案，这个限制防止了"一次性大改"的风险。前三轮反思（v1–v3）共 9 条提案，覆盖了最关键的系统缺陷（stub 过大 / canonical 噪音 / 打分无区分度），而不是试图一次解决所有问题。

9.3 学习模式的变化

阶段	主要学习来源	修正方式
v1–v3	actions.jsonl 的统计规律	直接改 Skill 文件
v4–v6	用户反馈 + 日志模式	Skill + 脚本双线修复
v7	具体 bug（鲁桓公）	全量数据重写 + 规则收紧
v8	定量诊断（K / 链接命中率）	新增工具链 + 批量生成
R35+	W6 质检	修复存量 + 提高标准

十、量化成果

指标	起点（种子）	v8 首快照	R50 时刻
wiki 页面数	~3	229	370+
精品页数	0	10	120+
K 值	—	13,336	~18,265
链接命中率	—	20.8%	~50%+
Skill 文件数	6（W0–W5）	7（+W6）	7
skill_changes.md 条目	0	31	40+

K 值从首快照到 R50 增长约 **37%**，时间跨度约 1.5 天。

十一、结论

Butler 的自进化不是一个线性的"越来越好"过程，而是由三种力量共同驱动：

1. 内生反思 (**W5**)：周期性地从统计数据中发现系统性偏差，每次保守修订 (≤ 3 条)，循序渐进
2. 外部纠错 (用户反馈 + **W6** 质检)：发现人工无法预期的边缘问题 (鲁桓公误匹配 / 韩王信编造引文)，触发精确的局部修复
3. 目标演进 (**K** 度量)：每次反思的"视野"从"这 20 步做得如何"扩展到"全站知识量如何增长"，让优先级决策更有依据

三者的结合形成了一个保守但单调改进的自进化系统：每次反思只改三件事，每次 commit 只改 20 行，但这些小改动通过数百次迭代积累，产生了可观的知识增长。